

PROPOSAL SKRIPSI

Klasifikasi Jenis dan Tingkat Kerusakan Jalan Menggunakan Arsitektur VGG19: Studi Kasus DPUPR Kota Samarinda

Oleh:

**Muhammad Alif
2209106127**



**FAKULTAS TEKNIK
UNIVERSITAS MULAWARMAN**

**SAMARINDA
2025**

PROPOSAL SKRIPSI

Klasifikasi Jenis dan Tingkat Kerusakan Jalan Menggunakan Arsitektur VGG19: Studi Kasus DPUPR Kota Samarinda

Diajukan sebagai salah satu syarat untuk menyelesaikan pendidikan
pada Program Studi Strata 1 Informatika,
Fakultas Teknik, Universitas Mulawarman

Oleh:

**Muhammad Alif
2209106127**



**FAKULTAS TEKNIK
UNIVERSITAS MULAWARMAN**

**SAMARINDA
2025**

PROPOSAL SKRIPSI

Klasifikasi Jenis dan Tingkat Kerusakan Jalan Menggunakan Arsitektur VGG19: Studi Kasus DPUPR Kota Samarinda

Oleh:

Muhammad Alif
2209106127

Telah dibahas dalam Rapat Dosen Pembimbing pada [tgl, bln, tahun] dan
dinyatakan memenuhi syarat sebagai Skripsi, dengan Dosen Pembimbing:

- I. Prof. Dr. Anindita Septiarini, S.T., M. Cs
- II. Reza Wardhana, S.Kom., M.Eng

Koordinator Program Studi S1 Informatika,
Fakultas Teknik, Universitas Mulawarman,

Awang Harsa Kridalaksana, S.Kom., M.Kom.
NIP 19731229 200501 1 002

KATA PENGANTAR

Puji syukur kepada Allah SWT, Tuhan Yang Maha Esa sehingga dapat menyelesaikan proposal skripsi dengan judul **“Klasifikasi Jenis dan Tingkat Kerusakan Jalan Menggunakan Arsitektur VGG19: Studi Kasus DPUPR Kota Samarinda”**. Proposal ini disusun sebagai salah satu tahapan dalam menyelesaikan skripsi pada Fakultas Teknik, Universitas Mulawarman.

Oleh karena itu, pada kesempatan ini kami ingin mengucapkan terima kasih kepada semua pihak yang telah mendukung serta membantu saya selama proses penyusunan proposal skripsi, kepada:

1. Orang tua dan Saudara-saudara saya atas do'a, bimbingan serta kasih sayangnya.
2. Bapak Prof. Dr. Ir. H. Tamrin, S.T., M.T., IPU., APEC Eng., selaku Dekan Fakultas Teknik Universitas Mulawarman, atas fasilitas dan dukungan yang diberikan selama proses perkuliahan.
3. Bapak Awang Harsa Kridalaksana, S.Kom., M.Kom., selaku Koordinator Program Studi Informatika, atas bimbingan dan arahannya selama penyusunan proposal ini.
4. Ibu Prof. Dr. Anindita Septiarini, S.T., M.Cs, selaku Dosen Pembimbing I, yang telah memberikan arahan, saran, dan motivasi dalam penyusunan proposal ini.
5. Bapak Reza Wardhana, S.Kom., M.Eng., selaku Dosen Pembimbing II, yang telah memberikan bimbingan dan masukan yang sangat berharga bagi penyempurnaan penelitian ini. Segenap Dosen Program Studi Informatika, yang telah memberikan ilmu pengetahuan selama mengikuti perkuliahan.
6. Rekan-rekan seperjuangan yang terus memberikan dukungan semangat demi terselesainya tugas ini.

Saya menyadari bahwa proposal skripsi ini tidak luput dari berbagai kekurangan. Oleh karena itu, semua kritik dan saran yang bersifat memperbaiki demi kesempurnaan sangat diharapkan.

Samarinda,..... 2025

Penulis

DAFTAR ISI

	halaman
Halaman Judul	i
Halaman Pengesahan	ii
Kata Pengantar	iii
Daftar Isi	iv
Daftar Tabel	v
Daftar Gambar	vi
Daftar Lampiran	vii
Daftar Istilah/Lambang	viii
Daftar Singkatan	ix
 BAB I PENDAHULUAN	 1
1.1	1
1.2	4
1.3	4
1.4	4
1.5	5
1.6	5
 BAB II TINJAUAN PUSTAKA	 3
2.1	3
2.2	Error! Bookmark not defined.
2.3	18
2.3.1	18
2.3.2	Teori Pendukung Sub BAB
2.4	19
 BAB III METODOLOGI PENELITIAN	 7
3.1	37
3.2	37
3.3	37
3.4	37
3.5	37
3.6	37
3.7	38
 Daftar Pustaka	 9
Lampiran-Lampiran	11

Keterangan:
WAJIB menggunakan alat bantu TOC (Table of Contents) pada Microsoft Word.

DAFTAR TABEL

	<i>Halaman</i>
Tabel 1.1 <i>contents</i>	6
Tabel 2.2 <i>contents</i>	7

DAFTAR GAMBAR

	<i>Halaman</i>
Gambar 2.1 <i>contents</i>	8
Gambar 2.2 <i>contents</i>	18
Gambar 2.3 <i>contents</i>	19

DAFTAR LAMPIRAN

	<i>Halaman</i>
Lampiran 1 <i>contents</i>	42

DAFTAR ISTILAH/LAMBANG

Contents

Arti

DAFTAR SINGKATAN

Contents

Arti

BAB I

PENDAHULUAN

1.1 Latar Belakang

Infrastruktur jalan merupakan komponen penting dalam pembangunan regional karena berperan penting dalam mendukung mobilitas masyarakat, distribusi barang, dan pertumbuhan ekonomi (Biswas & Jain, 2025). Infrastruktur jalan yang berkualitas baik tidak hanya meningkatkan efisiensi transportasi, tetapi juga memiliki dampak langsung terhadap keselamatan pengguna jalan. Sebaliknya, jalan yang rusak dapat menyebabkan kerugian ekonomi, menghambat aktivitas masyarakat, dan meningkatkan risiko kecelakaan lalu lintas (Shaw et al., 2025).

Di berbagai wilayah, termasuk Kota Samarinda, masalah kerusakan jalan tetap menjadi perhatian serius. Faktor-faktor seperti beban kendaraan yang berlebihan, kondisi cuaca ekstrem, dan pemeliharaan yang tidak teratur sering mempercepat kerusakan (*Kerusakan Jalan Di Samarinda Masalah Sistemik, Akademisi Ungkap Masalah Keterbatasan Anggaran*, n.d.). Bentuk kerusakan yang umum meliputi retakan pada permukaan jalan, lubang jalan, dan permukaan jalan yang tidak rata. Jika kerusakan ini tidak ditangani segera, kualitas jalan akan terus menurun dan biaya perbaikan di masa depan akan lebih tinggi (Kurniawan et al., 2025).

Hingga saat ini, proses pelaporan kerusakan jalan oleh masyarakat umumnya dilakukan secara manual melalui formulir *online* seperti Google Forms. Meskipun praktis, metode ini memiliki beberapa keterbatasan, termasuk ketidakhadiran sistem validasi otomatis untuk foto yang dikirimkan, kesulitan dalam pengelolaan data, dan kurangnya transparansi antara masyarakat dan lembaga terkait (Nizamiyati & Brilliant, 2024). Penelitian oleh (Falasyfa & Avianto, 2024) juga menunjukkan bahwa pelaporan secara manual sering menimbulkan permasalahan seperti keterlambatan penanganan, data yang tidak terorganisir, dan minimnya umpan balik kepada pelapor. Berdasarkan kondisi tersebut, dikembangkan sistem pelaporan berbasis web bernama Jalan Peduli, yang

dirancang agar proses pelaporan dapat dilakukan secara lebih terstruktur, transparan, dan efisien.

Namun, sistem ini masih memiliki kelemahan pada tahap validasi laporan. Proses verifikasi kondisi jalan masih dilakukan secara manual oleh petugas yang memeriksa foto-foto yang dikirimkan oleh masyarakat satu per satu (Probo Sumirat et al., 2021). Proses ini memakan waktu, rentan terhadap kesalahan manusia karena bersifat sangat subjektif dan tergantung dari penilai (Angreni, 2024), serta tidak efisien pada skala besar (Pandapotan et al., 2020). Kesenjangan antara kebutuhan akan validasi yang cepat dan akurat dengan keterbatasan proses manual inilah yang menjadi celah penelitian (*research gap*) utama yang ingin diatasi. Oleh karena itu, diperlukan teknologi yang dapat secara otomatis dan akurat mengklasifikasikan jenis dan tingkat kerusakan jalan menggunakan metode machine learning (Rahman et al., 2025), sehingga mempercepat pengambilan keputusan oleh pihak berwenang dan mendukung efisiensi biaya serta waktu dalam pemantauan berkelanjutan (Denaro & Lim, 2025).

Dalam beberapa tahun terakhir, perkembangan teknologi kecerdasan buatan (AI), khususnya di bidang pemrosesan gambar digital, telah membuka peluang besar dalam mendukung pengelolaan infrastruktur publik (Harahap & Kembaren, 2025). Salah satu pendekatan yang paling populer dan teruji dalam analisis gambar adalah Jaringan Saraf Konvolusional (CNN). CNN mampu mengekstrak fitur visual mendalam dari sebuah gambar dan mengklasifikasikan objek berdasarkan pola visual tertentu (Zhang et al., 2022). Teknologi ini telah digunakan dalam berbagai bidang seperti deteksi retak beton, identifikasi kondisi jalan, dan analisis permukaan aspal (Kulambayev et al., 2024).

Dalam konteks penelitian ini, penerapan CNN diharapkan dapat membantu sistem Jalan Peduli dalam mengidentifikasi jenis kerusakan jalan, seperti retak, lubang, atau permukaan tidak rata, serta menentukan tingkat keparahan kerusakan (Mulyana et al., 2025). Untuk mencapai tujuan tersebut, penelitian ini mengusulkan penggunaan arsitektur VGG19 dengan metode Transfer Learning. Pemilihan VGG19 didasarkan pada studi terbaru yang menunjukkan bahwa model ini memiliki stabilitas tinggi dalam

mengeksktraksi fitur tekstur visual jalan raya dan mampu mencapai akurasi klasifikasi yang superior dibandingkan arsitektur lain pada kondisi lingkungan yang bervariasi (Assemblali et al., 2025). Selain itu, penerapan Transfer Learning diadopsi untuk mengatasi tantangan keterbatasan jumlah data lokal di Samarinda, di mana metode ini terbukti efektif mempercepat konvergensi model dan mencegah overfitting meskipun dilatih dengan dataset yang terbatas (Baroudi et al., 2025). Dengan pendekatan ini, sistem tidak hanya berfungsi sebagai alat pelaporan, tetapi juga sebagai validator otomatis yang cerdas dan efisien.

Selain itu, penelitian ini dilakukan menggunakan dataset lokal, yaitu foto-foto kondisi jalan yang dikumpulkan secara manual di wilayah Kota Samarinda. Pendekatan ini dipilih karena kondisi jalan di setiap wilayah memiliki karakteristik yang berbeda, baik dari segi tekstur permukaan, pencahayaan, maupun pola kerusakan (Hugo et al., 2025). Dengan menggunakan data lokal, model CNN yang dikembangkan akan lebih adaptif dan relevan dengan kondisi nyata di lapangan, sehingga hasil klasifikasi dapat diterapkan secara lebih efektif di lingkungan lokal.

Secara keseluruhan, penelitian ini bertujuan untuk merancang dan mengimplementasikan sebuah sistem klasifikasi jenis dan tingkat kerusakan jalan menggunakan metode CNN, yang diintegrasikan ke dalam sistem pelaporan Jalan Peduli. Secara praktis, penelitian ini berkontribusi dalam menyediakan solusi untuk otomatisasi proses validasi laporan, sehingga meningkatkan efisiensi dan kecepatan respons perbaikan oleh dinas terkait. Secara teoretis, hasil penelitian ini diharapkan dapat memperkaya studi tentang penerapan deep learning untuk manajemen infrastruktur cerdas, khususnya dengan menggunakan dataset lokal yang merefleksikan kondisi jalan yang sebenarnya di Indonesia. Dengan demikian, penelitian ini tidak hanya menjadi solusi teknis, tetapi juga acuan untuk pengembangan kota cerdas (*smart city*) yang lebih responsif dan berbasis data.

1.2 Rumusan Masalah

Berdasarkan latar belakang penelitian, maka yang menjadi rumusan masalah dalam penelitian ini adalah :

1. Bagaimana menerapkan arsitektur VGG19 dengan metode Transfer Learning untuk mengklasifikasikan jenis dan tingkat kerusakan jalan pada dataset lokal Samarinda?
2. Bagaimana kinerja (akurasi, precision, recall) model VGG19 dalam mengenali pola kerusakan jalan di Samarinda dengan variasi pencahayaan dan tekstur yang beragam?
3. Bagaimana efisiensi waktu validasi laporan kerusakan jalan menggunakan model VGG19 dibandingkan dengan proses validasi manual pada sistem Jalan Peduli?

1.3 Batasan Masalah

Penelitian ini disusun berdasarkan data-data yang diperoleh. Luasnya bidang yang dihadapi membuat penelitian ini harus dibatasi. Ruang lingkup masalah dibatasi pada:

1. Penelitian terbatas pada dataset foto manual dari Samarinda (tidak termasuk data *aerial* atau *real-time* dari drone).
2. Fokus penelitian adalah klasifikasi citra (image classification), bukan deteksi objek (object detection), sehingga output berupa label kategori, bukan bounding box.
3. Implementasi pada sistem Jalan Peduli hanya sebatas prototipe klasifikasi (API/Modul), tidak mencakup pengembangan aplikasi full-stack atau keamanan sistem. Asumsi data berupa foto statis, bukan video atau sensor IoT.
4. Studi kasus spesifik pada karakteristik jalan di Kota Samarinda dan tidak digeneralisasi untuk wilayah lain di Kalimantan Timur.

1.4 Tujuan Penelitian

Tujuan yang ingin dicapai dalam penelitian ini adalah :

1. Membangun dan mengimplementasikan model klasifikasi kerusakan jalan menggunakan arsitektur VGG19 dengan metode Transfer Learning yang mampu mengklasifikasikan jenis dan tingkat kerusakan pada dataset lokal Samarinda.
2. Mengevaluasi performa model VGG19 berdasarkan metrik akurasi, precision, recall, dan F1-score dalam mengenali pola kerusakan jalan dengan variasi kondisi pencahayaan dan tekstur.
3. Menganalisis peningkatan efisiensi waktu validasi pelaporan kerusakan jalan dengan membandingkan proses otomatisasi model VGG19 terhadap proses manual pada sistem Jalan Peduli.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat pada berbagai pihak, khususnya:

1. Penulis

Manfaat bagi penulis adalah memperdalam pemahaman dan keterampilan dalam mengimplementasikan algoritma Deep Learning, khususnya arsitektur VGG19, untuk klasifikasi jenis dan tingkat kerusakan jalan menggunakan dataset lokal Samarinda.

2. Mahasiswa

Memberikan referensi akademis mengenai penerapan metode Transfer Learning pada arsitektur CNN dengan dataset terbatas. Penelitian ini diharapkan dapat menjadi acuan bagi mahasiswa Informatika dalam pengembangan sistem pemrosesan citra digital untuk kasus infrastruktur.

3. Instansi/Lembaga/Perusahaan

Membantu DPUPR Kota Samarinda dalam memperoleh validasi laporan kerusakan jalan yang lebih konsisten dan cepat melalui sistem otomatisasi berbasis AI. Hal ini diharapkan dapat mendukung efisiensi manajemen infrastruktur serta mempercepat respon penanganan perbaikan jalan.

1.6 Kontribusi Penelitian

Kontribusi utama penelitian ini adalah pengembangan model VGG19 berbasis Transfer Learning yang secara spesifik dilatih untuk karakteristik jalan di Kota

Samarinda. Penelitian ini juga berkontribusi dalam menyediakan dataset lokal yang terannotasi (jenis dan tingkat kerusakan), yang dapat menjadi referensi bagi pengembangan Smart City di Indonesia, serta memberikan solusi validasi otomatis untuk mengatasi bottleneck pada pelaporan manual di DPUPR.

BAB II

TINJAUAN PUSTAKA

2.1 Penelitian Terkait

Dalam rangka mendukung penelitian ini, maka dilakukan kajian dengan mempelajari penelitian-penelitian terkait yang telah dilakukan sebelumnya. Daftar penelitian terkait antara lain:

1. **Metode yang digunakan:** *Gray-Level Cooccurrence Matrix (GLCM)* untuk ekstraksi fitur tekstur, *Genetic Algorithm (GA)* untuk seleksi fitur, dan *Extreme Learning Machine (ELM)* untuk klasifikasi kerusakan jalan (potholes).
Temuan penelitian: Data yang digunakan berupa video kondisi jalan di Kota Malang, Jawa Timur, Indonesia, yang berisi citra jalan normal dan jalan berlubang. Dataset dilatih menggunakan 200 citra jalan normal dan 200 citra berlubang yang diambil dari video beresolusi 640×480 piksel. Penelitian dilakukan melalui beberapa tahap pengujian, yaitu:
(1) Pengujian ekstraksi fitur GLCM dengan delapan fitur utama (Contrast, Dissimilarity, Homogeneity, Energy, Angular Second Moment, Correlation, Entropy, dan Inverse Difference) pada sudut 0°, 45°, 90°, dan 135°.
(2) Pengujian seleksi fitur menggunakan *Genetic Algorithm* untuk mengoptimalkan 128 fitur menjadi kombinasi 57, 20, dan 12 fitur terbaik.
(3) Klasifikasi dilakukan menggunakan *Extreme Learning Machine (ELM)* dengan pembagian data latih 70% dan data uji 30%, serta fungsi aktivasi *sigmoid*.
(4) Hasil pengujian menunjukkan bahwa kombinasi 57 fitur menghasilkan akurasi 88,65% dengan waktu komputasi 0,115 detik, sedangkan kombinasi 20 fitur memberikan akurasi 87,36% dengan waktu 0,069 detik, dan 12 fitur memberikan akurasi 86,48% dengan waktu 0,062 detik. Kesimpulannya, metode GLCM–GA–ELM mampu mendeteksi lubang jalan secara real-time dengan akurasi tinggi dan waktu komputasi rendah, namun masih terbatas pada fitur tekstur manual dan belum menggunakan pembelajaran mendalam seperti CNN (Utaminigrum et al., 2023).

2. **Metode yang digunakan:** *Faster Regional Convolutional Neural Network (Faster R-CNN)* dengan tiga *backbone architecture* yaitu **VGG-16**, **ResNet-50**, dan **MobileNetV2**. **Temuan penelitian:** Data yang digunakan berupa 665 citra jalan rusak (pothole) yang diambil dari sumber publik dan kemudian melalui proses seleksi kualitas (menghapus citra buram, terlalu gelap, atau kontras tinggi). Dataset dibagi menjadi data latih 80% (532 citra) dan data uji 20% (133 citra). (1) Proses *augmentasi data* dilakukan dengan teknik rotasi dan flipping (horizontal, vertikal, dan rotasi 90° kanan–kiri) untuk meningkatkan variasi citra dan mencegah *overfitting*. (2) Model *Faster R-CNN* dibangun menggunakan *Region Proposal Network (RPN)* dengan backbone berbeda (VGG-16, ResNet-50, dan MobileNetV2). Optimizer yang digunakan adalah Stochastic Gradient Descent (SGD) dengan *learning rate* 0.00092 dan momentum 0.8. (3) Pengujian dilakukan dengan rasio *Intersection over Union (IoU)* ≥ 0.5 , serta metrik evaluasi berupa Precision, Recall, dan mean Average Precision (mAP). (4) Hasil menunjukkan bahwa model dengan backbone MobileNetV2 memberikan kinerja terbaik dengan nilai mAP sebesar 79,7%, diikuti oleh ResNet-50 (72,1%) dan VGG-16 (71,1%). Namun, model MobileNetV2 memerlukan jumlah epoch pelatihan paling banyak yaitu 67 epoch, dibandingkan dengan 31 (VGG-16) dan 29 (ResNet-50). Penelitian menyimpulkan bahwa Faster R-CNN dengan backbone MobileNetV2 memberikan hasil paling akurat dalam mendeteksi kerusakan jalan jenis lubang (*pothole*) meskipun masih memiliki keterbatasan dalam mendeteksi lubang tertutup air atau berukuran kecil (Rachman et al., 2022).
3. **Metode yang digunakan:** *Faster Regional-Convolutional Neural Network (Faster R-CNN)* dan *You Only Look Once v5 (YOLOv5)* untuk deteksi kerusakan jalan secara global. **Temuan penelitian:** Data yang digunakan adalah Global Road Damage Dataset 2020, yang berisi 21.041 citra dari tiga negara (Czech Republic, Jepang, dan India), masing-masing diberi label jenis kerusakan jalan berupa longitudinal crack (D00), transverse crack (D10), alligator crack (D20), dan pothole (D40). (1) Dataset dibagi dengan proporsi 80% data latih, 15% validasi, dan 5% uji, dengan ukuran citra 600×600 piksel dan format anotasi PASCAL VOC (XML). (2)

Peneliti melakukan pra-pemrosesan dengan DeepLab V3+ segmentation untuk memisahkan permukaan jalan dari latar belakang, namun hasil menunjukkan tidak ada peningkatan performa yang signifikan, sehingga model akhir dilatih tanpa segmentasi. (3) Eksperimen dilakukan menggunakan dua pendekatan: model per negara dan model generalisasi lintas negara. Model per negara memberikan peningkatan 1,5% pada skor F1 rata-rata, namun model generalisasi dipilih karena lebih efisien untuk penerapan global. (4) Pada model Faster R-CNN dengan backbone ResNet-50 + Feature Pyramid Network (FPN) dan batch size 640, diperoleh nilai Average F1 Score sebesar 0,5426 pada Test2 dataset, sedangkan YOLOv5-m (CSPNet backbone) hanya mencapai $F1 = 0,4714$. (5) Parameter pelatihan terbaik: Learning Rate (LR) = 0.01, scheduler step (23k, 25k, 26k), dan epoch maksimum 30k. Proses pelatihan menggunakan Detectron2 (PyTorch) di GPU NVIDIA 1080Ti. Kesimpulannya, Faster R-CNN memberikan hasil deteksi lebih akurat dibanding YOLOv5, khususnya untuk tipe kerusakan D20 (alligator crack) dan D40 (pothole). Penelitian ini menunjukkan bahwa model two-stage detector dengan backbone ResNet-50 lebih general dan stabil dibanding model kompleks seperti ResNet-101, serta cocok untuk penerapan global lintas wilayah (Vishwakarma & Vennelakanti, 2020).

4. **Metode yang digunakan:** *Convolutional Neural Network (CNN)* berbasis *VGG-19* dengan pendekatan *transfer learning* dan *Softmax classifier* untuk klasifikasi jenis kerusakan jalan. **Temuan penelitian:** Dataset yang digunakan terdiri dari 100 citra asli kerusakan jalan (berisi lima kategori: lubang, depresi, retak satu arah, kelonggaran, dan retak umum) yang kemudian diperluas menjadi 3.000 citra melalui proses *augmentation* menggunakan teknik rotasi, flipping diagonal, dan *edge extension*. Setiap gambar diubah ke format 256×256 piksel grayscale, dengan pembagian data latih sebesar 80% dan data uji 20%. Model *VGG-19* diterapkan menggunakan strategi *transfer learning*, di mana seluruh lapisan konvolusional dan *pooling layer* dibekukan (*frozen layers*), sedangkan lapisan *fully connected* dilatih ulang menggunakan fungsi *cross-entropy loss* dan *Softmax classifier* untuk lima kelas target. Parameter pelatihan meliputi *batch size* 20, *epoch* sebanyak 20, *learning rate* 0.0005, *momentum* 0.9, dan fungsi aktivasi *ReLU*. Model *VGG-19*

kemudian dibandingkan dengan *VGG-16*, *ResNet-121*, dan *ResNet-50* untuk mengevaluasi akurasi. Hasil menunjukkan bahwa *VGG-19* memberikan akurasi validasi tertinggi sebesar 86,2% dengan *loss rate* 0.4043, lebih tinggi 6–30% dibandingkan model lainnya (*VGG-16* = 82,6%; *ResNet-121* = 65,7%; *ResNet-50* = 60,4%). Kesimpulannya, metode *CNN* berbasis *VGG-19* dengan *transfer learning* terbukti efektif untuk deteksi dan klasifikasi cerdas kerusakan jalan dengan data terbatas. Model ini unggul dalam kemampuan generalisasi serta efisiensi komputasi, sehingga layak diterapkan dalam sistem pemantauan otomatis jalan raya (Tang et al., 2022).

5. **Metode yang digunakan:** *Convolutional Neural Network (CNN)* berbasis *Cascade RCNN* yang dikombinasikan dengan arsitektur *Length-aware cascaded damage detection network (CrdNet)* menggunakan backbone *LrNet*. **Temuan penelitian:** Dataset yang digunakan terdiri atas 7.282 citra resolusi tinggi (2048×2048 piksel) dari jalan raya di Provinsi Guangdong, Tiongkok, yang mencakup tujuh jenis kerusakan yaitu *longitudinal crack (LC)*, *transverse crack (TC)*, *repair (R)*, *poor repair (PR)*, *pothole (P)*, *crazing (C)*, dan *block repair (BR)*. Dari total data, 6.550 citra digunakan untuk pelatihan dan 732 citra untuk pengujian. Model *CrdNet* memiliki tiga komponen utama yaitu: (1) *LrNet backbone network* untuk mengekstraksi fitur multi-level dengan penggabungan *low-level feature aggregation module (LFAM)* dan *multi-scale attention module (MSAM)* guna mempertahankan detail tekstur dan memperkuat representasi fitur diskriminatif; (2) *Multi-scale and multiple aspect ratios anchor mechanism (MSARM)* untuk menghasilkan *anchor boxes* dengan berbagai rasio dan skala yang mampu mendeteksi kerusakan dengan bentuk memanjang atau tidak beraturan; (3) *Length-aware head* dengan tiga cabang konvolusional paralel dan fungsi *ROI adaptive assignment* berdasarkan panjang kerusakan yang memungkinkan deteksi bertingkat (*cascade detection*) sesuai panjang area kerusakan. Proses pelatihan menggunakan *SGD optimizer* dengan *momentum* 0,9, *batch size* 2, dan *learning rate* awal 0,01 yang diturunkan menjadi 0,001 dan 0,0001 pada *epoch* ke-20 dan 40. Hasil eksperimen menunjukkan bahwa *CrdNet* dengan backbone *LrNet* mencapai nilai *mean average precision (mAP)* tertinggi sebesar **90,92%**, lebih unggul 9,84%

dibanding *Faster RCNN+* dan 8,83% dibanding *Cascade RCNN+*. Model ini terbukti unggul dalam mendeteksi kerusakan kecil maupun memanjang di bawah kondisi pencahayaan kompleks, berkat kemampuan *multi-scale attention* dan strategi *length-aware cascading*. Penelitian ini menyimpulkan bahwa arsitektur CrdNet secara signifikan meningkatkan akurasi deteksi serta robust terhadap pencahayaan buruk dan variasi geometrik jalan (Xu et al., 2021).

6. **Metode yang digunakan:** *Convolutional Neural Network (CNN)* dengan kombinasi fitur *Grayscale* dan *Histogram of Oriented Gradients (HOG)* yang disebut sebagai *Grayscale-Weighted HOG (GHOG)*. **Temuan penelitian:** Penelitian ini bertujuan mengembangkan metode deteksi kerusakan jalan tol yang cepat dan efisien dengan menggabungkan fitur gradasi abu-abu dan orientasi gradien sebelum proses klasifikasi menggunakan CNN. Dataset yang digunakan adalah *GAPs v2* yang terdiri dari 50.000 citra latih dan 10.000 citra uji, mencakup berbagai jenis kerusakan seperti retak, lubang, dan tambalan pada permukaan jalan aspal. Tahapan metode meliputi (1) *Gamma correction* untuk memperbaiki kontras dan memperjelas perbedaan area kerusakan terhadap latar belakang, (2) ekstraksi fitur HOG dengan membagi citra menjadi beberapa sel dan menghitung gradien arah menggunakan operator Sobel, (3) pembobotan HOG berdasarkan nilai intensitas abu-abu pada setiap sel untuk membentuk citra GHOG berdimensi $19 \times 19 \times 36$, dan (4) pelatihan CNN dengan empat lapisan konvolusional berfungsi *ReLU* dan *MaxPooling*, diikuti *fully connected layers* beraktivasi *Sigmoid* dan *ReLU*. Parameter pelatihan meliputi *batch size* 25, *learning rate* 0.0001, serta 100 iterasi pelatihan. Hasil pengujian menunjukkan bahwa model GHOG-CNN mencapai akurasi sebesar **95%**, precision **94,76%**, recall **92,86%**, dan F1-score **93,8%**, jauh lebih baik dibanding model HOG-CNN dengan akurasi hanya **83,9%**. Selain itu, metode GHOG-CNN menunjukkan efisiensi komputasi tinggi karena dapat bekerja dengan citra resolusi tinggi tanpa kehilangan detail penting. Kesimpulannya, kombinasi fitur GHOG dan CNN meningkatkan akurasi deteksi serta robust terhadap kondisi pencahayaan dan tekstur yang bervariasi, menjadikannya solusi potensial untuk penerapan deteksi otomatis kerusakan jalan secara real-time (Chen et al., 2022).

7. **Metode yang digunakan:** *Convolutional Neural Network (CNN)* berbasis *ResNet18* yang dioptimalkan menggunakan mekanisme *Edge-Enhanced Multi-Scale Feature Fusion (EE-MSFF)* untuk meningkatkan deteksi dan klasifikasi kerusakan jalan. **Temuan penelitian:** Penelitian ini memperkenalkan integrasi antara teknik deteksi tepi tradisional (Sobel, Prewitt, dan Laplacian) dengan CNN melalui modul EE-MSFF guna memperkuat fitur tepi dan memperbaiki kemampuan model dalam membedakan area retak dari latar belakang kompleks. Dataset yang digunakan terdiri dari dua sumber data: *RDD2020* (4.174 citra dengan empat jenis kerusakan D00 longitudinal crack, D10 transverse crack, D20 alligator crack, dan D40 pothole) dan *Concrete_Data_Week3* (40.000 citra biner: crack dan non-crack). Citra dibagi menjadi 80% data latih dan 20% data uji, kemudian diproses menggunakan kombinasi multi-skala konvolusi berukuran 3×3 , 5×5 , dan 7×7 untuk menghasilkan peta fitur tepi yang digabungkan secara hierarkis. Model dilatih menggunakan *Adam optimizer* dengan *learning rate* 0,01, *batch size* 4, dan *cross-entropy loss function* selama 200 epoch untuk RDD2020 dan 40 epoch untuk *Concrete_Data_Week3*. Hasil eksperimen menunjukkan bahwa integrasi modul EE-MSFF meningkatkan akurasi klasifikasi dari **86,34% menjadi 88,68%** pada dataset RDD2020 dan mencapai **99,5%** pada dataset *Concrete_Data_Week3*. Selain itu, nilai precision, recall, dan F1-score juga meningkat masing-masing menjadi 89,57%, 87,55%, dan 88,42%. Hasil *ablation study* membuktikan bahwa peningkatan akurasi sebesar 2,34% berasal langsung dari kontribusi modul EE-MSFF yang mampu memfokuskan perhatian model pada area tepi retakan. Visualisasi *heatmap* menunjukkan bahwa model yang dioptimalkan lebih sensitif terhadap area kerusakan dibanding model dasar ResNet18. Kesimpulannya, integrasi *edge-enhanced multi-scale feature fusion* memperkuat representasi fitur CNN terhadap tepi dan tekstur halus, meningkatkan ketahanan model terhadap gangguan latar belakang, serta memberikan kinerja setara dengan model yang lebih kompleks seperti YOLOv8 dan DeiT, namun dengan arsitektur lebih ringan dan efisien (Wang et al., 2025).
8. **Metode yang digunakan:** *Federated Learning (FL)* dengan arsitektur *YOLOv5l* sebagai model deteksi objek untuk mendeteksi kerusakan jalan secara global tanpa

perlu berbagi data antarnegara. **Temuan penelitian:** Penelitian ini dilakukan untuk mengatasi masalah keterbatasan data dan privasi dalam pelatihan model deteksi kerusakan jalan lintas negara. Model FL dikembangkan menggunakan kerangka *Flower Framework* yang terintegrasi dengan *PyTorch YOLOv5l* serta metode agregasi *Federated Averaging (FedAvg)*. Dataset yang digunakan berasal dari *RDD2022*, yang berisi 22.660 citra dari enam negara yaitu Jepang, India, Amerika Serikat, Cina, Norwegia, dan Republik Ceko, dengan empat kategori kerusakan yaitu *longitudinal crack*, *transverse crack*, *alligator crack*, dan *pothole*. Model diuji pada dua skenario: (1) pelatihan lokal per negara (single-country) dan (2) kolaborasi multicountry (non-IID data). Pada setiap skenario, FL dilatih menggunakan *batch size* 4, *input size* 640×640 piksel, dan 60 *server rounds* dengan 1 *local epoch* per klien. Hasil menunjukkan bahwa model FL memiliki performa 21–25% lebih rendah dibandingkan model *centralized training* dalam hal *mean Average Precision (mAP)*, tetapi tetap mengungguli model lokal tiap negara dengan peningkatan mAP sebesar 1,33%–163% pada data uji global. Khusus untuk data multicountry dengan distribusi non-IID, FL menunjukkan kemampuan generalisasi yang lebih baik terhadap data lintas wilayah dibandingkan model lokal, bahkan ketika diuji pada negara yang tidak ikut pelatihan (contohnya Republik Ceko). Penelitian ini juga menemukan bahwa semakin banyak jumlah klien yang berpartisipasi, semakin baik performa model hingga titik optimal sebelum biaya komunikasi meningkat signifikan. Model federasi ini memungkinkan pelatihan bersama antarnegara tanpa melanggar privasi data, menghasilkan model deteksi kerusakan jalan global yang kuat dan adaptif. Kesimpulannya, FL dengan YOLOv5l merupakan pendekatan inovatif yang mampu membangun model deteksi kerusakan jalan global tanpa perlu transfer data mentah antarserver, sekaligus menjaga privasi dan efisiensi sumber daya komputasi (Saha et al., 2024).

9. **Metode yang digunakan:** Convolutional Neural Network (CNN) berbasis YOLOv5 yang dioptimalkan dengan tiga modul utama: Convolutional Block Attention Module (CBAM), Atrous Spatial Pyramid Pooling dengan Squeeze-and-Excitation (AS-SE), dan EIoU loss function, yang secara kolektif disebut sebagai Cycle-YOLO. **Temuan penelitian:** Penelitian ini bertujuan mengembangkan

framework deteksi kerusakan jalan yang efisien dan robust dengan mengatasi masalah ketidakseimbangan kelas data dan kompleksitas latar belakang jalan. Model Cycle-YOLO dikembangkan dengan mengintegrasikan metode augmentasi data berbasis improved Scharr filter, CycleGAN, dan Laplacian pyramid untuk memperkaya dataset, serta memodifikasi arsitektur YOLOv5 dengan menambahkan CBAM untuk meningkatkan fokus pada area kerusakan, mengganti modul SPPF dengan AS-SE untuk ekstraksi fitur multi-skala tanpa mengurangi resolusi, dan mengoptimalkan fungsi loss dari CIOU menjadi EIoU untuk mempercepat konvergensi. Dataset yang digunakan berasal dari 12.658 citra jalan yang dikumpulkan selama tiga bulan, yang setelah dibersihkan menghasilkan 3.644 citra kerusakan (1.620 lubang/KC, 1.230 retak/LF, 794 tambalan/XB) dan 4.000 citra tanpa kerusakan. Data kemudian diperluas menggunakan metode augmentasi gabungan menjadi 6.176 citra dengan distribusi seimbang untuk tiga kelas kerusakan. Model diuji dengan membandingkan performanya terhadap YOLOv5 asli, YOLOv5 dengan modul individual (CBAM, SPPF, EIoU), serta model lebih maju seperti YOLOv7 dan Faster R-CNN. Pada setiap skenario, model dilatih menggunakan SGD optimizer dengan learning rate awal 0.01, batch size 32, dan 300 epoch. Hasil menunjukkan bahwa model Cycle-YOLO mencapai precision 87.2%, recall 85.4%, dan mAP@0.5 sebesar 88.2%, melampaui YOLOv7 (mAP 87.8%) dan YOLOv5 asli (mAP 85.1%). Khusus untuk deteksi pada latar belakang kompleks, CBAM meningkatkan recall sebesar 0.8%, sementara AS-SE memberikan kontribusi signifikan terhadap peningkatan mAP sebesar 3.1% dibandingkan SPPF. Penelitian ini juga menemukan bahwa penggunaan EIoU loss function mempercepat konvergensi model dan meningkatkan precision sebesar 1.9% dibandingkan CIOU. Model ini mampu memproses 68 frame per detik (FPS) pada GPU, memenuhi syarat untuk deteksi real-time. Kesimpulannya, integrasi augmentasi data CycleGAN-Laplacian dengan arsitektur YOLO-ASCE menghasilkan model yang tidak hanya unggul dalam akurasi tetapi juga efisien secara komputasi, menjadikannya solusi yang sangat potensial untuk penerapan sistem monitoring kerusakan jalan otomatis oleh DPUPR Kota Samarinda (Li et al., 2024).

10. **Metode yang digunakan:** Convolutional Neural Network (CNN) berbasis Faster R-CNN dengan backbone X-101-FPN yang diperkaya dengan teknik augmentasi data Cut-and-Paste yang sadar konten (content-aware) dan perspektif (perspective-aware). **Temuan penelitian:** Penelitian ini dilakukan untuk mengatasi keterbatasan teknik augmentasi data standar yang sering mengabaikan lokasi logis objek (dalam hal ini, permukaan jalan) dan perbedaan perspektif antara citra kerusakan yang disisipkan dengan citra target, yang menghasilkan data sintetis yang tidak realistis dan mengurangi efektivitas pelatihan model. Model yang diusulkan dikembangkan dengan mengintegrasikan tiga komponen utama: (1) kesadaran konten, yang dicapai dengan memanfaatkan model segmentasi semantik pra-terlatih untuk menghasilkan *road mask* biner yang membatasi area penyisipan kerusakan hanya pada permukaan jalan; (2) kesadaran perspektif, yang diimplementasikan dengan mengelompokkan citra berdasarkan rentang sudut kemiringan kamera (*pitch angle*) dan menyisipkan kerusakan dari citra dengan rentang perspektif yang serupa, serta menerapkan transformasi perspektif untuk menyesuaikan skala dan orientasi; dan (3) teknik *Poisson blending* untuk menyatukan kerusakan dengan latar belakang secara halus dan alami. Dataset yang digunakan dalam penelitian ini adalah bagian Jepang dari RDDC2022, yang berisi 22.660 citra dengan empat kategori anotasi kerusakan, yaitu Longitudinal Crack (D00), Transverse Crack (D10), Alligator Crack (D20), dan Pothole (D40). Model dievaluasi dengan tiga skenario augmentasi yang berbeda: (1) model *baseline* tanpa augmentasi khusus, (2) model dengan augmentasi Cut-and-Paste standar, dan (3) model dengan metode augmentasi yang diusulkan (content- dan perspective-aware). Pada setiap skenario, model dilatih menggunakan pembagian data 90% untuk pelatihan dan 10% untuk pengujian. Hasil menunjukkan bahwa model yang dilatih dengan metode augmentasi yang diusulkan mencapai mean Average Precision pada IoU 50% (mAP50) sebesar 58,19%, meningkat 1,67 poin persentase dibandingkan model *baseline* (56,52%) dan 0,24 poin persentase dibandingkan model dengan augmentasi Cut-and-Paste standar (56,95%). Peningkatan performa paling signifikan terlihat pada kelas kerusakan D40 (Pothole) dengan kenaikan Average Precision (AP) sebesar 2,71 poin, dari 21,58% menjadi 24,29%, serta pada kelas D20 (Alligator Crack) yang

naik dari 33,00% menjadi 35,13%. Penelitian ini juga menemukan bahwa teknik augmentasi yang diusulkan mampu menurunkan nilai *loss* pada data uji menjadi 0,81, lebih rendah dibandingkan model *baseline* (0,86) dan model Cut-and-Paste standar (0,83), yang mengindikasikan kemampuan generalisasi model yang lebih baik dan terhindar dari *overfitting*. Secara visual, citra hasil augmentasi terbukti lebih realistis dan kontekstual, di mana kerusakan tampak menyatu dengan baik dengan permukaan jalan dan perspektif yang sesuai. **Kesimpulannya**, pendekatan augmentasi data Cut-and-Paste yang mempertimbangkan konten dan perspektif secara signifikan mampu meningkatkan kualitas data sintetis, yang pada akhirnya meningkatkan akurasi dan ketahanan model deteksi kerusakan jalan, terutama untuk kelas kerusakan yang menantang seperti *pothole* dan *alligator crack*. Metode ini memberikan solusi yang efektif dan efisien untuk memperkaya dataset dalam pengembangan sistem monitoring infrastruktur jalan otomatis, seperti yang dapat diadopsi oleh Dinas Pekerjaan Umum dan Penataan Ruang (DPUPR) Kota Samarinda (Siripathitti et al., n.d.).

Perbedaan dengan Penelitian Sebelumnya

Berdasarkan referensi yang terkait, maka didapatkan perbedaan penelitian yang terdahulu sebagai dasar penelitian ini adalah fokus pada penerapan studi kasus yang spesifik dan integrasi sistem yang praktis.

Jika sebagian besar penelitian sebelumnya seperti yang dilakukan oleh Vishwakarma & Vennelakanti (2020) dan Saha et al. (2024) berfokus pada penggunaan dataset global untuk generalisasi model, penelitian ini secara khusus menggunakan dataset lokal yang dikumpulkan dari kondisi jalan di Kota Samarinda. Pendekatan ini dipilih untuk memastikan model CNN yang dikembangkan lebih relevan dan adaptif terhadap karakteristik unik kerusakan, tekstur permukaan, dan pencahayaan di wilayah tersebut, sehingga menghasilkan klasifikasi yang lebih efektif untuk lingkungan lokal.

Selanjutnya, perbedaan mendasar lainnya terletak pada tujuan akhir. Penelitian lain umumnya berhenti pada pengembangan atau perbandingan akurasi arsitektur CNN,

seperti yang ditunjukkan oleh Rachman et al. (2022) dan Tang et al. (2022) . Sebaliknya, penelitian ini bertujuan untuk mengintegrasikan model klasifikasi ke dalam sistem pelaporan "Jalan Peduli" untuk mengotomatisasi proses validasi, yang secara langsung mengatasi celah penelitian terkait verifikasi manual yang lambat dan subjektif.

Terakhir, model yang diusulkan dirancang untuk melakukan klasifikasi ganda, yaitu mengidentifikasi jenis kerusakan (retak, lubang, permukaan tidak rata) dan tingkat keparahannya (ringan, sedang, berat). Ini memberikan informasi yang lebih komprehensif dibandingkan beberapa studi sebelumnya yang cenderung hanya berfokus pada deteksi satu jenis kerusakan atau klasifikasi umum saja. Dengan demikian, penelitian ini menawarkan solusi yang tidak hanya unggul secara teknis tetapi juga dirancang khusus untuk kebutuhan praktis DPUPR Kota Samarinda.

2.2 Kerusakan Jalan

Kerusakan jalan adalah penurunan kondisi perkerasan yang menyebabkan permukaan tidak mampu memberikan tingkat pelayanan yang memuaskan bagi pengguna jalan. Kerusakan ini dapat berupa cacat struktural maupun fungsional yang terjadi akibat kombinasi faktor beban lalu lintas, kondisi lingkungan, kualitas material, dan pemeliharaan yang tidak memadai (Chu et al., 2022).

2.2.1 Jenis Kerusakan

Dalam penelitian ini, klasifikasi kerusakan jalan difokuskan pada tiga jenis kerusakan utama yang paling sering dijumpai :

A. Lubang (*pothole*) adalah depresi berbentuk mangkuk pada permukaan perkerasan yang terbentuk akibat melemahnya struktur perkerasan dari infiltrasi air berkepanjangan, beban lalu lintas berulang, atau pemeliharaan yang tidak memadai. Lubang menimbulkan risiko keselamatan signifikan bagi pengguna jalan, terutama kendaraan roda dua, karena menyebabkan depresi mendadak pada permukaan jalan. Berdasarkan kriteria kerusakan, lubang dengan diameter rata-rata 575 mm dan kedalaman 40 mm termasuk dalam kategori tingkat kerusakan tinggi (Aqila et al., 2025).

- B. Retak (*crack*)** adalah garis pecah atau patahan pada permukaan perkerasan yang muncul dalam berbagai bentuk seperti retak memanjang (*longitudinal cracking*), retak melintang (*transverse cracking*), dan retak kulit buaya (*alligator cracking*). Retak permukaan umumnya disebabkan oleh ekspansi termal, beban kendaraan berlebih, atau degradasi material jalan. Retak memanjang terjadi sejajar dengan garis tengah jalan akibat tegangan termal, penyusutan aspal, atau refleksi retak dari lapisan di bawahnya. Berdasarkan lebar retak, kategori kerusakan sedang ditunjukkan dengan lebar retak rata-rata 2 cm (Aqila et al., 2025).
- C. Permukaan tidak rata** adalah kondisi deformasi atau ketidakrataan permukaan jalan yang mencakup alur (*rutting*), gelombang, atau penurunan diferensial. Alur merupakan deformasi permanen pada jalur roda akibat beban kendaraan berat berulang dan kegagalan struktural lapisan perkerasan. Faktor seperti jenis lapisan dasar, ketebalan lapisan dasar, beban lalu lintas kumulatif, suhu, dan curah hujan memiliki pengaruh signifikan terhadap kedalaman alur. Alur dengan kedalaman kurang dari 1 cm termasuk dalam kategori kerusakan ringan (Aqila et al., 2025).

2.2.2 Contoh Jenis Kerusakan

Contoh visualisasi jenis kerusakan jalan ditunjukkan pada Gambar 2.1 hingga 2.3. Setiap citra diambil dari dataset lokal Kota Samarinda yang digunakan dalam penelitian ini, meliputi jenis lubang, retak, dan permukaan tidak rata.



Gambar 2. 1 Contoh Kerusakan Jalan Lobang di Jl. Milono

Pada **Gambar 2.1** ditampilkan contoh kerusakan jalan berupa lubang (*pothole*) yang diambil dari situs Jalan Peduli milik DPUPR Kota Samarinda (2025). Kerusakan ini terlihat sebagai depresi berbentuk cekungan pada permukaan aspal yang terjadi akibat beban lalu lintas berulang dan genangan air.



Gambar 2. 2 Contoh Kerusakan Jalan Retak di Jl. Adi Sucipto

Pada **Gambar 2.2** ditunjukkan contoh kerusakan jalan jenis retak (*crack*) dengan pola menyerupai kulit buaya (*alligator cracking*) yang diambil dari laporan masyarakat melalui situs Jalan Peduli DPUPR Kota Samarinda. Kerusakan ini tampak sebagai garis-garis pecah yang saling berpotongan di permukaan jalan akibat penuaan aspal, tegangan termal, dan beban lalu lintas berulang. Jenis retak seperti ini termasuk kategori kerusakan sedang

karena menunjukkan penurunan kekuatan struktural pada lapisan perkerasan dan berpotensi berkembang menjadi lubang apabila tidak segera ditangani.



Gambar 2. 3 Contoh Kerusakan Jalan Permukaan Tidak Rata di Jl. Pusaka

Pada **Gambar 2.3** diperlihatkan contoh permukaan jalan tidak rata (*rutting*) yang bersumber dari laporan masyarakat pada situs Jalan Peduli DPUPR Kota Samarinda. Kondisi permukaan jalan tampak mengalami deformasi atau penurunan pada jalur roda kendaraan akibat tekanan berulang dari kendaraan berat. Ketidakrataan ini menyebabkan alur memanjang di permukaan jalan dan dapat menimbulkan genangan air saat hujan, sehingga menurunkan kenyamanan dan keselamatan pengguna jalan. Berdasarkan karakteristiknya, kerusakan ini termasuk dalam kategori kerusakan ringan hingga sedang, tergantung pada kedalaman alur yang terbentuk.

2.2.3 Tingkat Kerusakan

Tingkat kerusakan jalan pada penelitian ini ditentukan secara kualitatif berdasarkan pola dan tekstur kerusakan yang tampak pada citra permukaan jalan, bukan berdasarkan pengukuran geometris luas kerusakan. Pendekatan ini sejalan dengan penelitian deteksi dan klasifikasi kerusakan jalan berbasis citra digital yang menilai kondisi jalan melalui bentuk retak, lubang, dan deformasi permukaan (Sasmito et al., 2023).

- A. **Ringan (*Low Severity*)**: Kerusakan permukaan minor seperti retak rambut, pelepasan butir aspal ringan, atau lubang kecil dan dangkal yang secara visual belum mengubah struktur utama perkerasan serta belum mengganggu kenyamanan berkendara secara signifikan (Sasmito et al., 2023).
- B. **Sedang (*Medium Severity*)**: Kerusakan yang tampak jelas pada citra, misalnya retak yang mulai melebar dan saling terhubung, lubang dengan kedalaman menengah, atau permukaan bergelombang yang mulai mengganggu kenyamanan pengguna jalan dan menandakan penurunan kemampuan layan (Sasmito et al., 2023).
- C. **Berat (*High Severity*)**: Kerusakan struktural parah yang secara visual mendominasi citra, seperti retak kulit buaya yang rapat dan menyebar, lubang besar dan dalam, penurunan setempat, atau deformasi berat lainnya yang berpotensi membahayakan keselamatan pengguna jalan dan membutuhkan perbaikan segera (Sasmito et al., 2023).

Pendekatan visual ini selaras dengan penggunaan model CNN dan VGG19, di mana model mempelajari fitur tekstur dan pola kerusakan dari citra penuh tanpa memerlukan anotasi bounding box untuk menghitung luas kerusakan (Wang et al., 2023a).

2.2.4 Faktor Penyebab Kerusakan

Kerusakan jalan disebabkan oleh kombinasi beberapa faktor utama :

Beban lalu lintas berlebih merupakan faktor dominan yang menyebabkan kelelahan struktural perkerasan akibat repetisi beban kendaraan berat yang melampaui kapasitas desain. Infiltrasi air dan drainase buruk menyebabkan air meresap melalui celah retak ke lapisan bawah perkerasan, melemahkan daya dukung tanah dasar, dan mempercepat pembentukan lubang. Kondisi lingkungan seperti fluktuasi suhu ekstrem dan curah hujan tinggi memiliki pengaruh signifikan terhadap percepatan kerusakan, di mana ekspansi termal dan kontraksi material menyebabkan retakan permukaan. Karakteristik

struktural meliputi jenis dan ketebalan lapisan dasar yang berpengaruh terhadap kinerja kelelahan dan kerentanan terhadap deformasi. Degradasi material jalan akibat oksidasi aspal dan penuaan menyebabkan kehilangan fleksibilitas sehingga permukaan menjadi rentan terhadap retak. Kualitas kontrol konstruksi yang rendah, termasuk pemadatan yang tidak optimal dan campuran material yang tidak sesuai spesifikasi, mempercepat kerusakan dini (Bhandari et al., 2023).

2.3 Citra Digital


Citra digital adalah representasi visual dari suatu objek atau pemandangan dalam bentuk array dua dimensi yang terdiri dari elemen-elemen diskrit yang disebut piksel (*picture element*). Setiap piksel menyimpan informasi intensitas warna atau tingkat kecerahan pada posisi tertentu dalam gambar. Dalam konteks deteksi kerusakan jalan menggunakan CNN, citra digital berfungsi sebagai input data yang akan diekstraksi fitur-fiturnya untuk mengenali pola kerusakan pada permukaan jalan (Haque et al., 2022).

2.3.1 Representasi Citra Digital

Menurut (Haque et al., 2022) Citra digital dapat direpresentasikan dalam berbagai ruang warna (*color space*), dengan yang paling umum adalah RGB (Red, Green, Blue). Dalam sistem RGB, setiap piksel direpresentasikan oleh tiga nilai yang menunjukkan intensitas warna merah, hijau, dan biru dengan rentang nilai 0-255 untuk format 8-bit. Oleh karena itu, sebuah citra RGB terdiri dari tiga channel independen atau tiga "*layer*" di mana setiap *layer* menyimpan nilai intensitas warna pada posisi piksel yang sama. Apabila ketiga channel ini digabungkan, maka akan membentuk citra warna utuh sebagaimana tampak oleh mata .

Pada **Gambar 2.4** di bawah ini ditampilkan ilustrasi representasi citra RGB yang dipecah menjadi tiga channel warna. Pada bagian kiri atas merupakan citra asli jalan yang mengalami kerusakan, sedangkan tiga gambar di bawahnya menunjukkan hasil ekstraksi dari masing-masing channel warna, yaitu **Red (R)**, **Green (G)**, dan **Blue (B)**. Setiap

channel menampilkan intensitas warna tertentu pada citra, di mana kombinasi ketiganya akan membentuk kembali citra warna asli secara utuh.



Gambar 2. 4 Dekomposisi citra RGB menjadi tiga channel terpisah (Red, Green, Blue)

Dalam penelitian ini, citra kerusakan jalan diproses dalam format RGB dengan ukuran standar 224×224 piksel dan memiliki 3 channel warna (Red, Green, Blue). Dimensi ini menghasilkan *input shape* (224, 224, 3) yang menjadi masukan untuk arsitektur CNN. Struktur tiga dimensi ini direpresentasikan sebagai tensor dengan dimensi lebar $\times$ tinggi $\times$ channel, di mana setiap channel menyimpan matriks nilai intensitas warna tertentu (Haque et al., 2022).

2.4 Machine Learning dan Deep Learning

2.4.1 Machine Learning

Machine learning adalah cabang dari kecerdasan buatan (*artificial intelligence*) yang memberikan kemampuan kepada sistem komputer untuk belajar

dan meningkatkan kinerjanya dari pengalaman tanpa diprogram secara eksplisit. Dalam *machine learning*, algoritma menggunakan data untuk membangun model matematis yang dapat membuat prediksi atau keputusan berdasarkan pola yang dipelajari dari data *training*. Pendekatan ini berbeda dengan pemrograman tradisional di mana programmer harus mendefinisikan aturan secara eksplisit untuk setiap kemungkinan skenario (Haque et al., 2022).

Machine learning dapat dikategorikan menjadi tiga jenis utama berdasarkan cara model belajar dari data :

a. **Supervised Learning (Pembelajaran Terawasi)**

Supervised Learning adalah pendekatan machine learning di mana model dilatih menggunakan kumpulan data yang telah diberi **label** secara eksplisit. Artinya, setiap data masukan (*input*) sudah memiliki pasangan data keluaran (*output*) yang benar. Tujuan dari model ini adalah untuk mempelajari "aturan" atau pemetaan dari input ke output, sehingga dapat memprediksi output untuk data baru yang belum pernah dilihat sebelumnya. (Dong et al., 2025).

b. **Unsupervised Learning (Pembelajaran Tidak Terawasi)**

Unsupervised Learning adalah jenis *machine learning* di mana model dilatih menggunakan data yang tidak memiliki label. Model harus menemukan pola, struktur, atau pengelompokan dalam data secara mandiri tanpa panduan output yang diinginkan (Dong et al., 2025).

c. **Reinforcement Learning (Pembelajaran Penguatan)**

Reinforcement Learning adalah jenis *machine learning* di mana agen belajar membuat keputusan dengan berinteraksi dengan lingkungan dan menerima *reward* atau penalti berdasarkan tindakan yang diambil. Agen belajar untuk memaksimalkan *reward* kumulatif dari waktu ke waktu (Haque et al., 2022).

2.4.2 Deep Learning

Deep learning adalah sub-bidang dari machine learning yang menggunakan jaringan saraf tiruan (*artificial neural network*) dengan banyak layer tersembunyi (*hidden layers*) untuk mempelajari representasi data secara hierarkis. Istilah "*deep*" merujuk pada kedalaman jaringan, yaitu jumlah *layer* yang digunakan untuk mentransformasi input menjadi output. Perkembangan *deep learning* telah merevolusi bidang *computer vision* dengan mencapai akurasi yang melampaui metode tradisional dalam tugas seperti klasifikasi citra dan deteksi objek (Liang et al., 2024).

Perkembangan *deep learning* telah merevolusi bidang *computer vision*, khususnya dalam aplikasi deteksi dan klasifikasi kerusakan jalan. Penelitian menunjukkan bahwa model *deep learning* seperti CNN dapat mencapai akurasi deteksi kerusakan jalan yang jauh lebih tinggi dibandingkan metode tradisional berbasis *machine learning* seperti SVM atau Random Forest. Keunggulan ini disebabkan oleh kemampuan *deep learning* dalam mengekstraksi fitur kompleks secara otomatis dari citra mentah tanpa memerlukan *feature engineering* manual (Ma & Chen, 2025).

Salah satu keunggulan utama *deep learning* adalah kemampuan ekstraksi fitur otomatis yang mengeliminasi kebutuhan *feature engineering* manual. Dalam metode tradisional, ahli domain harus merancang deskriptor fitur seperti HOG (*Histogram of Oriented Gradients*), SIFT (*Scale-Invariant Feature Transform*), atau analisis tekstur Gabor untuk mengidentifikasi karakteristik kerusakan jalan. Proses ini memerlukan pengetahuan domain yang mendalam, bersifat *time-consuming*, dan sering kali tidak optimal untuk variasi kondisi citra yang beragam (Liang et al., 2024).

Pembelajaran hierarkis merupakan karakteristik fundamental *deep learning* yang memungkinkan model membangun representasi data dalam tingkat abstraksi bertingkat. Layer konvolusi awal dalam arsitektur CNN mempelajari fitur visual tingkat rendah seperti tepi, sudut, dan tekstur permukaan. Layer konvolusi tengah mengombinasikan fitur-fitur tingkat rendah ini untuk membentuk

representasi tingkat menengah seperti bentuk geometris dan pola tertentu. Layer konvolusi dalam dan layer *fully connected* mempelajari fitur tingkat tinggi yang lebih abstrak, seperti representasi semantik lengkap dari objek atau kategori kerusakan spesifik (Dong et al., 2025).

Deep learning menunjukkan performa superior pada dataset berukuran besar dibandingkan dengan algoritma *machine learning* tradisional. Penelitian menunjukkan bahwa semakin banyak data annotated yang tersedia untuk training, performa model *deep learning* terus meningkat secara konsisten, sedangkan algoritma tradisional cenderung mencapai *plateau* setelah jumlah data tertentu. Fenomena ini menjadikan *deep learning* sangat sesuai untuk aplikasi deteksi kerusakan jalan yang dapat memanfaatkan dataset citra jalan skala besar dari berbagai sumber seperti survei kendaraan, drone, atau kamera CCTV (Ren et al., 2024).


Berbagai arsitektur *deep learning* telah dikembangkan untuk tugas-tugas spesifik dalam *computer vision*. **Convolutional Neural Network (CNN)** merupakan arsitektur yang dirancang khusus untuk pemrosesan data grid seperti citra dan telah menjadi standar untuk tugas klasifikasi citra, deteksi objek, dan segmentasi. **Recurrent Neural Network (RNN)** dirancang untuk pemrosesan data sekuensial seperti teks dan *time series*. **Generative Adversarial Network (GAN)** digunakan untuk generasi data sintetis dan *data augmentation*. Untuk aplikasi deteksi kerusakan jalan berbasis citra, CNN merupakan pilihan arsitektur yang paling sesuai dan akan dibahas secara detail pada sub-bab selanjutnya (Chu et al., 2022).

2.5 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) adalah arsitektur *deep learning* yang dirancang khusus untuk memproses data dengan struktur grid seperti citra digital. CNN menggunakan operasi konvolusi matematis sebagai mekanisme fundamental untuk mengekstraksi fitur spasial dari input, menggantikan operasi matriks perkalian umum yang digunakan pada jaringan saraf tiruan tradisional. Arsitektur ini telah menjadi standar

de facto untuk berbagai tugas *computer vision* termasuk klasifikasi citra, deteksi objek, segmentasi semantik, dan pengenalan pola visual (Liang et al., 2024).

CNN memiliki keunggulan signifikan dibandingkan dengan jaringan saraf tiruan *fully connected* tradisional dalam memproses citra. Pertama, CNN memanfaatkan struktur spasial lokal dalam citra melalui *receptive field* yang terbatas, sehingga dapat menangkap pola lokal seperti tepi, sudut, dan tekstur dengan efisien. Kedua, CNN menggunakan prinsip *weight sharing* di mana filter konvolusi yang sama diterapkan pada seluruh bagian citra, yang secara dramatis mengurangi jumlah parameter model dibandingkan dengan jaringan *fully connected*. Ketiga, CNN memiliki sifat *translation invariance* yang memungkinkan model mengenali objek yang sama meskipun posisinya berubah dalam citra (Ma & Chen, 2025).



Gambar 2. 5 Building Blocks of a CNN

Gambar 2.5 menunjukkan arsitektur umum **Convolutional Neural Network (CNN)** yang terdiri dari beberapa tahap utama, yaitu *feature extraction*, *classification*, dan *probabilistic distribution*. Pada tahap awal, citra masukan diproses melalui lapisan konvolusi (*convolution layer*) menggunakan filter (*kernel*) untuk mengekstraksi fitur-fitur penting seperti tepi dan tekstur, kemudian dilakukan *pooling* untuk mengurangi dimensi data tanpa kehilangan informasi utama. Hasil ekstraksi fitur tersebut diratakan melalui *flatten layer* dan diteruskan ke *fully connected layer* yang berfungsi sebagai pengklasifikasi utama. Pada tahap akhir, lapisan keluaran menggunakan fungsi aktivasi

Softmax untuk menghasilkan distribusi probabilitas terhadap setiap kelas. Secara keseluruhan, CNN mampu mempelajari pola visual dari citra dan melakukan klasifikasi secara otomatis, sehingga sangat efektif digunakan dalam penelitian ini untuk mengenali jenis dan tingkat kerusakan jalan (*Decoding CNNs: A Beginner's Guide to Convolutional Neural Networks and Their Applications* | by Ravjot Singh | Medium, n.d.).

2.5.1 Arsitektur CNN

Arsitektur CNN terdiri dari beberapa jenis layer yang bekerja secara hierarkis untuk mengekstraksi dan mengklasifikasikan fitur visual. Struktur umum CNN dapat dibagi menjadi dua bagian utama: *feature extraction layers* yang terdiri dari layer konvolusi dan *pooling*, serta *classification layers* yang terdiri dari layer *fully connected*. Setiap layer dalam CNN memiliki fungsi spesifik dalam mengubah representasi input menjadi representasi output yang lebih abstrak dan informatif (Azhari et al., 2025; Liang et al., 2024).

A. Convolutional Layer

Convolutional. layer merupakan komponen inti dari arsitektur CNN yang melakukan operasi konvolusi untuk mengekstraksi fitur dari citra input. *Layer* ini menggunakan sekumpulan *filter* atau kernel yang dapat dipelajari, di mana setiap filter merupakan matriks kecil dengan dimensi tertentu (misalnya 3×3 atau 5×5) yang digeser (*slide*) melintasi seluruh citra input (Liang et al., 2024).

Operasi konvolusi dapat direpresentasikan sebagai:

$$S(i, j) = (I * K)(i, j) = \sum_{m=-M}^M \sum_{n=-N}^N I(i + m, j + n) \cdot K(m, n) \quad (2.1)$$

Di mana pada **Rumus 2.1**:

- $S(i, j)$ = nilai output pada posisi koordinat (i, j) dalam *feature map* hasil konvolusi
- I = matriks citra input (gambar asli yang akan diproses)

- K = kernel atau filter konvolusi (matriks bobot yang dipelajari oleh model)
- (i, j) = koordinat posisi piksel dalam feature map output
- m, n = indeks untuk iterasi di dalam kernel/filter
- $*$ = operator konvolusi

Operasi ini menghitung hasil perkalian elemen per elemen antara filter dan region lokal citra, kemudian menjumlahkan hasilnya untuk menghasilkan satu nilai dalam feature map (Azhari et al., 2025).

B. Pooling Layer

Pooling layer berfungsi untuk mengurangi dimensi spasial dari *feature maps* yang dihasilkan oleh *convolutional layer*. Tujuan utama *pooling* adalah untuk mengurangi jumlah parameter dan komputasi dalam jaringan, mengendalikan *overfitting*, dan memberikan invarian terhadap translasi kecil dalam input (Azhari et al., 2025; Liang et al., 2024).

Jenis *pooling* yang paling umum digunakan adalah *max pooling*, yang dapat diformulasikan sebagai:

$$y_{i,j} = \max_{(m,n) \in R_{i,j}} x_{m,n} \quad (2.2)$$

Di mana pada **Rumus 2.2**:

- $y_{i,j}$ = nilai output pada posisi (i, j) setelah pooling
- $x_{m,n}$ = nilai piksel input pada koordinat (m, n)
- $R_{i,j}$ = region atau window pooling pada posisi (i, j) (biasanya berukuran 2×2)

- $\max$ = fungsi yang memilih nilai maksimum dari semua nilai dalam region

Max pooling memilih nilai maksimum dari setiap region lokal dalam feature map untuk mengurangi dimensi spasial (Liang et al., 2024).

Alternatif lain adalah *average pooling*:

$$y_{i,j} = \frac{1}{|R_{i,j}|} \sum_{(m,n) \in R_{i,j}} x_{m,n} \quad (2.3)$$

Di mana pada **Rumus 2.3**:

- $y_{i,j}$ = nilai output pada posisi (i, j) setelah pooling
- $x_{m,n}$ = nilai piksel input pada koordinat (m, n)
- $R_{i,j}$ = region atau window pooling pada posisi (i, j) (biasanya berukuran 2×2)
- $|R_{i,j}|$ = jumlah elemen dalam region pooling (misalnya untuk window 2×2 , nilainya adalah 4)
- $\sum$ = operator penjumlahan dari semua nilai dalam region

Average pooling menghitung rata-rata nilai dari setiap region lokal dalam feature map (Liang et al., 2024).

C. Flatten Layer

Flatten layer berfungsi untuk mengubah representasi multi-dimensi dari *feature maps* menjadi vector satu dimensi. Layer ini diperlukan sebagai penghubung antara *convolutional layers* yang menghasilkan output tiga dimensi (lebar $\times$ tinggi $\times$ channel) dan *fully connected layers* yang memerlukan input satu dimensi.

Jika input memiliki dimensi $h \times w \times d$ (height $\times$ width $\times$ depth/channels), maka output flatten adalah vector dengan dimensi $h \times w \times d$ elemen. Proses *flattening* tidak mengubah atau menghilangkan informasi dalam data, tetapi hanya merestrukturisasi format representasi.

D. Fully Connected Layer

Fully connected layer (juga dikenal sebagai *dense layer*) adalah layer di mana setiap *neuron* terhubung ke semua neuron pada *layer* sebelumnya. *Output* dari *fully connected layer* dapat diformulasikan sebagai:

$$y = f(Wx + b) \quad (2.4)$$

Di mana pada **Rumus 2.4**:

- y = vector *output* dari layer (hasil klasifikasi atau representasi fitur)
- W = matriks bobot yang dapat dipelajari (*weight matrix*)
- x = vector *input* dari *layer* sebelumnya (hasil *flatten* atau *output layer* sebelumnya)
- b = vector bias (nilai tambahan untuk setiap neuron)
- f = *activation function* yang diterapkan pada hasil (misalnya ReLU atau softmax)

Layer ini mengintegrasikan semua fitur yang telah diekstraksi untuk membuat prediksi akhir (Liang et al., 2024).

2.5.2 Activation Functions

Activation functions merupakan komponen penting dalam CNN yang memperkenalkan non-linearity ke dalam model. Tanpa *activation function*, jaringan saraf berlapis akan berperilaku seperti model linear sederhana (Azhari et al., 2025).

A. ReLU (Rectified Linear Unit)

ReLU adalah activation function yang paling umum digunakan dalam CNN modern. ReLU didefinisikan sebagai:

$$f(x) = \max(0, x) = \begin{cases} x, & \text{jika } x > 0 \\ 0, & \text{jika } x \leq 0 \end{cases} \quad (2.5)$$

Di mana pada **Rumus 2.5**:

- $f(x)$ = output setelah aktivasi ReLU
- x = nilai input (sebelum aktivasi)
- $\max(0, x)$ = memilih nilai maksimum antara 0 dan x

ReLU mengeluarkan nilai input jika positif, dan nol jika negatif, sehingga memperkenalkan non-linearity ke dalam model (Liang et al., 2024).

B. Softmax

Softmax activation function menurut (Liang et al., 2024) umumnya digunakan pada layer output untuk tugas klasifikasi multi-kelas. Softmax mengubah vector nilai numerik (logits) menjadi distribusi probabilitas:

$$\sigma(z)_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}} \quad (2.6)$$

Di mana pada **Rumus 2.6**:

- $\sigma(z)_j$ = probabilitas output untuk kelas ke- j
- z_j = nilai logit (*raw output*) untuk kelas ke- j dari layer sebelumnya
- K = jumlah total kelas dalam klasifikasi
- e = konstanta Euler (≈ 2.718)
- $\sum_{k=1}^K$ = penjumlahan untuk semua kelas dari 1 hingga K

Softmax mengubah vector nilai numerik menjadi distribusi probabilitas yang jumlahnya selalu 1 (Liang et al., 2024).

2.5.3 Dropout

Dropout menurut (Liang et al., 2024) adalah teknik *regularization* yang secara acak "mematikan" sejumlah neuron tertentu selama proses training untuk mencegah *overfitting*. Secara matematis, dropout dapat direpresentasikan sebagai:

$$r_j \sim \text{Bernoulli}(p) \quad (2.7)$$

Di mana pada **Rumus 2.7**:

- r_j = variabel acak untuk neuron ke- j (bernilai 0 atau 1)
- $\sim$ = simbol "mengikuti distribusi"
- $\text{Bernoulli}(p)$ = distribusi probabilitas Bernoulli dengan parameter p
- p = probabilitas neuron untuk tetap aktif (misalnya 0.5 berarti 50% neuron aktif)

Jika $r_j = 1$, neuron aktif; jika $r_j = 0$, neuron dimatikan (Liang et al., 2024).

$$\tilde{\mathbf{y}} = \mathbf{r} \odot \mathbf{y} \quad (2.8)$$

Di mana pada **Rumus 2.8**:

- $\tilde{\mathbf{y}}$ = output setelah *dropout* diterapkan
- $\mathbf{r}$ = vector mask *dropout* (berisi 0 dan 1 dari distribusi Bernoulli)

- y = *output* asli dari *layer* (sebelum dropout)
- $\odot$ = operator perkalian elemen per elemen (*element-wise multiplication* / *Hadamard product*)

Operasi ini secara efektif "mematikan" neuron yang dipilih secara acak (Liang et al., 2024).

Selama fase inferensi (*testing*), semua neuron diaktifkan tetapi *output* mereka diskala dengan faktor p untuk menjaga ekspektasi nilai yang konsisten dengan *training*. Penelitian menunjukkan bahwa *dropout* sangat efektif dalam meningkatkan generalisasi model CNN.

2.5.4 Training CNN

Training CNN melibatkan proses pembelajaran parameter model melalui algoritma optimasi. Proses ini menggunakan *backpropagation* untuk menghitung gradien fungsi *loss* terhadap setiap parameter (Azhari et al., 2025).

Loss Function untuk klasifikasi multi-kelas menggunakan *categorical cross-entropy*:

$$L = - \sum_{i=1}^K y_i \log(\hat{y}_i) \quad (2.9)$$

Di mana pada **Rumus 2.9**:

- L = nilai *loss* (kerugian) total
- K = jumlah total kelas dalam klasifikasi
- y_i = label sebenarnya untuk kelas ke- i (dalam format *one-hot*: 1 untuk kelas benar, 0 untuk lainnya)

- $\hat{y}_i$ = probabilitas yang diprediksi model untuk kelas ke-i (*output* dari *softmax*)
- $\log$ = logaritma natural
- $-$ = tanda negatif (karena kita ingin meminimalkan *loss*, dan log dari probabilitas selalu negatif)

Semakin kecil nilai L , semakin baik prediksi model (Liang et al., 2024).

Optimizer Adam sering digunakan karena efektivitasnya. Update parameter dengan Adam dapat diformulasikan sebagai (Azhari et al., 2025; Ma & Chen, 2025):

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (2.10)$$

Di mana pada **Rumus 2.10**:

- m_t = estimasi momen pertama (mean) dari gradien pada iterasi ke- t
- β_1 = koefisien decay untuk momen pertama (biasanya 0.9)
- m_{t-1} = estimasi momen pertama pada iterasi sebelumnya
- g_t = gradien pada iterasi ke- t
- t = nomor iterasi training

Momen pertama adalah moving average dari gradien (Liang et al., 2024).

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (2.11)$$

Di mana pada **Rumus 2.11**:

- v_t = estimasi momen kedua (*variance*) dari gradien pada iterasi ke- t
- β_2 = koefisien *decay* untuk momen kedua (biasanya 0.999)
- v_{t-1} = estimasi momen kedua pada iterasi sebelumnya

- g_t^2 = gradien dikuadratkan (*element-wise*)

Momen kedua adalah moving average dari gradien yang dikuadratkan (Liang et al., 2024).

$$\theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t \quad (2.12)$$

Di mana pada **Rumus 2.12**:

- θ_{t+1} = parameter model (bobot dan bias) yang diperbarui pada iterasi ke -t + 1
- θ_t = parameter model pada iterasi ke-t
- α = learning rate (kecepatan pembelajaran, misalnya 0.001)
- $\hat{m}_t$ = estimasi momen pertama yang telah dikoreksi bias
- $\hat{v}_t$ = estimasi momen kedua yang telah dikoreksi bias
- ϵ = konstanta kecil untuk stabilitas numerik (biasanya 10^{-8}) agar tidak terjadi pembagian dengan nol
- $\sqrt{\cdot}$ = akar kuadrat

Formula ini menggabungkan momentum dan adaptive learning rate untuk update parameter yang efisien (Liang et al., 2024).

2.5.5 Arsitektur VGG19

Arsitektur VGG19 merupakan salah satu varian *Convolutional Neural Network* (CNN) yang diperkenalkan oleh tim *Visual Geometry Group* (VGG) dari University of Oxford sebagai peserta kompetisi ImageNet Large Scale *Visual Recognition Challenge* (ILSVRC). VGG19 terdiri atas 19 lapisan berparameter, yaitu 16 lapisan konvolusi dan 3 lapisan fully connected, dengan penggunaan kernel konvolusi berukuran kecil 3×3 dan max pooling 2×2 secara berulang untuk membentuk representasi fitur yang semakin abstrak dan mendalam. Pendekatan desain yang sederhana namun dalam ini menjadikan

VGG19 efektif dalam mengekstraksi pola tekstur halus dan struktur objek pada citra resolusi tinggi, termasuk tekstur permukaan jalan (Wang et al., 2023a).

Pada arsitektur asli, VGG19 menerima masukan citra berukuran 224×224 piksel dengan tiga kanal warna (RGB), kemudian melewati beberapa blok konvolusi dan *pooling* sebelum diratakan di lapisan *flatten* dan diklasifikasikan melalui tiga lapisan *fully connected* dengan aktivasi Softmax pada output. Dalam konteks transfer learning, lapisan konvolusi VGG19 yang telah dilatih pada dataset ImageNet dimanfaatkan sebagai *feature extractor*, sedangkan lapisan atasnya dimodifikasi dan dilatih ulang untuk tugas khusus, seperti klasifikasi jenis dan tingkat kerusakan jalan. Pendekatan ini telah digunakan pada penelitian pengenalan dan klasifikasi kerusakan jalan berbasis VGG19 yang menunjukkan bahwa model mampu membedakan variasi pola retak dan kerusakan permukaan secara akurat (Arya et al., 2021).

2.6 Augmentasi Data

Menurut (Vishwakarma, 2020), augmentasi data adalah teknik memperkaya variasi data latih dengan melakukan transformasi pada citra (misalnya resize, perubahan orientasi, dan bentuk augmentasi lainnya) tanpa mengubah makna label kelas. Teknik ini digunakan untuk membantu model CNN lebih general dan tidak mudah overfitting ketika dataset terbatas atau memiliki variasi kondisi yang tinggi. Pada domain kerusakan jalan, augmentasi relevan karena foto dapat berasal dari berbagai perangkat, sudut kamera, dan kondisi lapangan yang tidak seragam.

Menurut (Siripathitti, 2023), augmentasi data digunakan untuk meningkatkan performa deteksi/klasifikasi kerusakan infrastruktur berbasis visi komputer, termasuk pada konteks kerusakan jalan, terutama ketika dataset bersifat tidak seimbang atau memiliki variasi kondisi pengambilan citra. (Siripathitti, 2023) juga menjelaskan bahwa pendekatan augmentasi dapat dikombinasikan dengan strategi lain (misalnya segmentasi atau pembuatan kerusakan sintetis) untuk membantu model lebih fokus pada area permukaan yang relevan.

Pada penelitian (Sufia Zareen et al., 2025), augmentasi seperti rotasi, flipping, zoom, serta penyesuaian kontras dan warna digunakan dalam tahap pra-pemrosesan untuk

membantu model lebih robust pada variasi kondisi citra jalan. Hal ini relevan dengan studi kasus laporan masyarakat karena foto jalan umumnya diambil dengan perbedaan sudut kamera dan pencahayaan yang tidak seragam.

Dalam penelitian ini, augmentasi data diterapkan pada data latih sebelum pelatihan VGG19 untuk meningkatkan variasi citra dan mengurangi risiko overfitting pada dataset lokal Samarinda yang jumlahnya terbatas. Augmentasi yang digunakan berfokus pada transformasi yang tidak mengubah label kelas, seperti rotasi ringan, flipping, dan penyesuaian kecerahan/kontras agar model lebih stabil terhadap variasi orientasi dan pencahayaan pada foto laporan.

2.7 Pembagian Dataset

Pemisahan dataset (data splitting) merupakan prosedur fundamental dalam pengembangan model pembelajaran mesin untuk menjamin validitas evaluasi kinerja. Menurut (Walsh et al., 2021), dataset harus dipartisi secara ketat menjadi himpunan bagian yang saling lepas (disjoint sets) guna mencegah terjadinya bias optimistis pada estimasi performa model. Dalam penelitian ini, dataset citra kerusakan jalan dibagi menjadi tiga subset fungsional, yaitu training set untuk proses optimisasi bobot model, validation set untuk penyetelan hiperparameter (hyperparameter tuning) serta pemantauan konvergensi guna mendeteksi overfitting, dan test set yang berperan sebagai data uji independen untuk evaluasi akhir.

Penentuan proporsi pembagian dataset didasarkan pada keseimbangan antara kebutuhan data latih yang cukup untuk generalisasi model dan data uji yang representatif untuk evaluasi statistik. (Dash et al., 2025) menekankan bahwa validasi yang reliabel mensyaratkan independensi penuh antara proses pelatihan dan pengujian; pelanggaran terhadap prinsip ini, seperti penggunaan informasi statistik data uji dalam pra-pemrosesan atau augmentasi, dapat memicu fenomena data leakage. Kebocoran data tersebut berpotensi menyebabkan inflasi metrik evaluasi, di mana model seolah-olah memiliki akurasi tinggi namun gagal melakukan generalisasi pada data baru di lingkungan produksi.

Untuk memitigasi risiko tersebut, (Joeres et al., 2025) merekomendasikan strategi pemisahan yang mempertimbangkan struktur data, khususnya pada dataset citra yang

memiliki korelasi tinggi antar-sampel. Mengacu pada rekomendasi tersebut, penelitian ini menerapkan strategi pemisahan data di mana seluruh proses augmentasi dan transformasi data hanya diterapkan pada *training set*, sementara *validation set* dan *test set* dipertahankan dalam kondisi aslinya untuk merepresentasikan distribusi data riil yang akan dihadapi sistem saat diimplementasikan.

2.8 Training Model

Pelatihan model merupakan tahapan fundamental dalam Deep Learning di mana algoritma mengoptimalkan bobot jaringan untuk meminimalkan kesalahan prediksi. Dalam proses ini, strategi pengelolaan data memegang peranan vital. (Conciatori et al., 2024) menekankan bahwa validitas model sangat bergantung pada prosedur pemisahan dataset (data splitting) yang ketat, di mana data harus dipartisi menjadi himpunan bagian yang saling lepas (disjoint sets) untuk mencegah bias optimisme pada hasil evaluasi akhir.

Dalam konteks deteksi kerusakan jalan, (Hasan & Ahmed, 2025) menjabarkan bahwa dataset idealnya dibagi menjadi tiga subset fungsional:

1. **Training Set:** Digunakan untuk proses pembelajaran fitur visual utama (seperti tekstur retakan atau lubang) melalui optimisasi bobot.
2. **Validation Set:** Digunakan untuk memantau konvergensi pelatihan serta penyetelan hiperparameter (*hyperparameter tuning*) guna mendeteksi gejala *overfitting* sedini mungkin.
3. **Test Set:** Berfungsi sebagai data uji independen yang hanya digunakan pada tahap akhir untuk mengukur kemampuan generalisasi model terhadap kondisi jalan yang benar-benar baru.

Selain itu, untuk mengatasi masalah komputasi seperti VGG19, Menurut (Wang et al., 2023b) metode transfer learning yang menggunakan bobot pra-latihan dari dataset berskala besar terbukti efektif untuk mendeteksi kerusakan jalan dengan lebih akurat. Metode ini juga mempercepat waktu pelatihan dibandingkan dengan metode pelatihan awal (scratch).

2.9 Evaluasi Model

Evaluasi Model bertujuan untuk mengukur keandalan model dalam mengklasifikasikan jenis dan tingkat kerusakan jalan secara objektif. Dasar evaluasi ini menggunakan Confusion Matrix, yang menurut (Rainio et al., 2024), didefinisikan sebagai tabel instrumen untuk memetakan perbandingan antara prediksi sistem dengan label aktual (kebenaran dasar).

Berdasarkan instrumen tersebut, kinerja model diukur menggunakan metrik statistik sebagai berikut:

1. Akurasi (*Accuracy*)
2. Presisi (*Precision*)
3. Recall (*Sensitivity*)
4. F1-Score

Penulisan tabel seperti ini.

Tabel 2.1. Tabel Data Mahasiswa Informatika

No.	Nama Mahasiswa	NIM	L/P	Program Studi
1		1815025063	L	S1 Informatika
2		1815025121	L	S1 Informatika
3		1715015068	L	S1 Informatika
4		1715025029	P	S1 Informatika
5		1815025123	L	S1 Informatika
6			L	S1 Informatika
7			L	S1 Informatika

BAB III

METODOLOGI PENELITIAN

3.1 Tahapan Pelaksanaan Penelitian

Penjelasan lihat di ppt

3.2 Pengumpulan Data

Penjelasan lihat di ppt

3.3 Perancangan Data

Penjelasan lihat di ppt

3.4 Perancangan Proses/Algoritma

Penjelasan lihat di ppt. Penulisan rumus matematik ditulis ulang menggunakan tools pada Word seperti Equation atau Math Type, **tidak boleh dari hasil capture.**

3.5 Perancangan Tampilan

Penjelasan lihat di ppt

3.6 Perancangan Pengujian

Penjelasan lihat di ppt

3.7 Waktu dan Tempat Penelitian

Penelitian ini akan dilaksanakan pada bulan sampai bulan tahun Adapun tempat pelaksanaan penelitian dilakukan di Instansi/Lembaga/Perusahaan, sedangkan analisis data dilakukan pada Laboratorium, Fakultas Teknik, Universitas Mulawarman.

Berbagai aktivitas dan kegiatan dalam penelitian ini dapat terjadwal dan selesai sesuai dengan waktu yang telah ditentukan, maka perlu disusun dalam suatu jadwal penelitian yang dapat dilihat pada Tabel 3.x.

Tabel 3.x Jadwal Penelitian

No	Kegiatan	Bulan (Tahun)							
		Jan	Feb	Mar	Apr	Mei	Juni	Juli	Agust
I	Tahap Persiapan Penelitian								
	1. Pembuatan Proposal								
	2. Seminar Proposal								
	3. Perbaikan Seminar Proposal								
	4. ...								
II	Tahap Pelaksanaan								
	1. Pengumpulan Data								
	2. Mengolah Data dan analisis								
	3. ...								
III	Tahap Penyusunan Laporan								
	1. Seminar Hasil								
	2. Perbaikan Seminar Hasil								
	3. Penulisan Artikel Ilmiah								
	4. Seminar Akhir								

	5. Perbaikan Seminar Akhir								
	6. ...								

DAFTAR PUSTAKA

- Angreni, I. A. A. (2024). KLASIFIKASI KERUSAKAN JALAN: RETAK, RETAK KULIT BUAYA DAN LUBANG BERDASARKAN CITRA DIGITAL. *Jurnal Ilmiah Desain & Konstruksi*, 23(2), 253–260. <https://doi.org/10.35760/DK.2024.V23I2.11389>
- Aqila, M. F., Said, S., & Kadarini, S. N. (2025). Analysis of Road Surface Deterioration Level Using Surface Distress Index and Pavement Condition Index at Jalan Rasau Jaya-Sungai Bulan. *Jurnal Teknik Sipil*, 25(1), 1704–1718. <https://doi.org/10.26418/jts.v25i1.88373>
- Arya, D., Maeda, H., Ghosh, S. K., Toshniwal, D., Mraz, A., Kashiyama, T., & Sekimoto, Y. (2021). Deep learning-based road damage detection and classification for multiple countries. *Automation in Construction*, 132, 103935. <https://doi.org/10.1016/J.AUTCON.2021.103935>
- Assemblali, H., Bouhsissin, S., & Sael, N. (2025). Computer Vision-Based Detection and Classification of Road Obstacles: Systematic Literature Review. In *IEEE Access* (Vol. 13, pp. 128603–128638). Institute of Electrical and Electronics Engineers Inc. <https://doi.org/10.1109/ACCESS.2025.3588668>
- Azhari, F. A., Rohana, T., Baihaqi, K. A., & Fauzi, A. (2025). Road Damage Detection Using Yolov9-Based Imagery. *Jurnal Sisfokom (Sistem Informasi Dan Komputer)*, 14(2), 196–201. <https://doi.org/10.32736/sisfokom.v14i2.2377>
- Baroudi, U., Bahamid, A., Elalfy, Y., & Al Alami, Z. (2025). *Enhancing Pothole Detection and Characterization: Integrated Segmentation and Depth Estimation in Road Anomaly Systems*.
- Bhandari, S., Luo, X., & Wang, F. (2023). Understanding the effects of structural factors and traffic loading on flexible pavement performance. *International Journal of Transportation Science and Technology*, 12(1), 258–272. <https://doi.org/10.1016/J.IJTST.2022.02.004>
- Biswas, S., & Jain, R. (2025). The Road to Safety - Examining the Nexus between Road Infrastructure and Crime in Rural India. *Journal of Quantitative Economics*, 1–24. <https://doi.org/10.1007/S40953-025-00466-6/METRICS>
- Chen, G. H., Ni, J., Chen, Z., Huang, H., Sun, Y. L., Ip, W. H., & Yung, K. L. (2022). Detection of Highway Pavement Damage Based on a CNN Using Grayscale and HOG Features. *Sensors*, 22(7). <https://doi.org/10.3390/s22072455>
- Chu, C., Wang, L., & Xiong, H. (2022). A review on pavement distress and structural defects detection and quantification technologies using imaging approaches. *Journal of Traffic and Transportation Engineering (English Edition)*, 9(2), 135–150. <https://doi.org/10.1016/J.JTTE.2021.04.007>
- Conciatori, M., Valletta, A., & Segalini, A. (2024). Improving the quality evaluation process of machine learning algorithms applied to landslide time series analysis. *Computers & Geosciences*, 184, 105531. <https://doi.org/10.1016/J.CAGEO.2024.105531>

- Dash, S., Luhach, A., & Chicco, D. (2025). *The ABC recommendations for validation of supervised machine learning results in biomedical sciences*.
- Decoding CNNs: A Beginner's Guide to Convolutional Neural Networks and their Applications* / by Ravjot Singh | Medium. (n.d.). Retrieved October 20, 2025, from <https://ravjot03.medium.com/decoding-cnns-a-beginners-guide-to-convolutional-neural-networks-and-their-applications-1a8806cbf536>
- Denaro, L. G., & Lim, R. (2025). Analisis Deteksi Kerusakan pada Jalan Aspal menggunakan Deep Learning untuk Mendukung Efisiensi Biaya dan Waktu dalam Pemantauan Berkelanjutan. *Jurnal Dimensi Insinyur Profesional*, 3(1), 16–25. <https://doi.org/10.9744/JDIP.3.1.16-25>
- Dong, S., Wang, Y., Cao, J., Ma, J., Chen, Y., & Kang, X. (2025). Advanced lightweight deep learning vision framework for efficient pavement damage identification. *Scientific Reports*, 15(1), 1–15. <https://doi.org/10.1038/S41598-025-97132-X>;SUBJMETA
- Falasyfa, R. S., & Avianto, D. (2024). Perancangan Aplikasi Layanan Pengaduan Kerusakan Jalan Berbasis Android. *Jurnal Indonesia : Manajemen Informatika Dan Komunikasi*, 5(1), 944–953. <https://doi.org/10.35870/jimik.v5i1.569>
- Haque, M. A., Marwaha, S., Arora, A., Deb, C. K., Misra, T., Nigam, S., & Hooda, K. S. (2022). A lightweight convolutional neural network for recognition of severity stages of maydis leaf blight disease of maize. *Frontiers in Plant Science*, 13. <https://doi.org/10.3389/fpls.2022.1077568>
- Harahap, L. S., & Kembaren, M. F. H. (2025). Klasifikasi Objek Menggunakan Convolutional Neural Network pada Citra Satelit. *RIGGS: Journal of Artificial Intelligence and Digital Business*, 4(2), 4663–4667. <https://doi.org/10.31004/RIGGS.V4I2.1306>
- Hasan, M. M., & Ahmed, B. (2025). Improving Road Safety through Deep Learning-based Approaches for Road Damage Detection and Classification. In *International Journal of Computer Applications* (Vol. 186, Issue 76).
- Hugo, B., Zakiyyah, A. Y., & Minor, K. A. (2025). EfficientDet Model for Accurate Detection and Classification of Road Damages in Indonesia. *Journal of Machine Learning and Deep Learning*, 2(1), 11–17. <https://doi.org/10.64820/AEPJMLDL.21.11.17.62025>
- Joeres, R., Blumenthal, D. B., & Kalinina, O. V. (2025). Data splitting to avoid information leakage with DataSAIL. *Nature Communications*, 16(1). <https://doi.org/10.1038/s41467-025-58606-8>
- Kerusakan Jalan di Samarinda Masalah Sistemik, Akademisi Ungkap Masalah Keterbatasan Anggaran*. (n.d.). Retrieved October 8, 2025, from <https://kaltimtoday.co/kerusakan-jalan-di-samarinda-masalah-sistemik-akademisi-ungkap-masalah-keterbatasan-anggaran>
- Kulambayev, B., Gleb, B., Katayev, N., Menglibay, I., Momynkulov, Z., & University, T. (2024). Real-Time Road Damage Detection System on Deep Learning Based Image Analysis. In

- IJACSA) International Journal of Advanced Computer Science and Applications* (Vol. 15, Issue 9). www.ijacsa.thesai.org
- Kurniawan, A., Patriadi, A., & Sajiyo, S. (2025). Analysis of the Correspondence Between the Type of Road Damage and the Budget Costs Incurred in Handling on Provincial Roads in the Madura Region. *International Journal of Mechanical, Electrical and Civil Engineering*, 2(1), 149–156. <https://doi.org/10.61132/IJMECIE.V2I1.140>
- Li, Z., Xiao, X., Xie, J., Fan, Y., Wang, W., Chen, G., Zhang, L., & Wang, T. (2024). *Cycle-YOLO: A Efficient and Robust Framework for Pavement Damage Detection*. <http://arxiv.org/abs/2405.17905>
- Liang, J., Zhang, Q., & Gu, X. (2024). Small-sample data-driven lightweight convolutional neural network for asphalt pavement defect identification. *Case Studies in Construction Materials*, 21, e03643. <https://doi.org/10.1016/J.CSCM.2024.E03643>
- Ma, L., & Chen, M. (2025). Road damage detection based on improved YOLO algorithm. *Scientific Reports*, 15(1), 1–12. <https://doi.org/10.1038/S41598-025-14461-7;SUBJMETA>
- Mulyana, D. I., Wahyudi, I., Studi, P., Komputer, I., Tinggi, S., Karya Informatika, C., Kota, J., Timur, D., Khusus, I., & Jakarta, I. (2025). Deteksi Kerusakan Jalan Berdasarkan Citra Digital Menggunakan Convolutional Neural Network (CNN). In *Jurnal Indonesia : Manajemen Informatika dan Komunikasi (JIMIK)* (Vol. 6, Issue 1). <https://journal.stmiki.ac.id>
- Nizamiyati, N., & Brilliant, M. (2024). Road Damage Detection and Reporting System Using YOLOv7: Enhancing Public Participation in Infrastructure Maintenance. *International Journal of Engineering Continuity*, 3(2), 69–85. <https://doi.org/10.58291/ijec.v3i2.302>
- Pandapotan, I. A., Siahaan, D., & Fatichah, C. (2020). Pengembangan Modul Pengolah Data Citra untuk Aplikasi Pemetaan Kerusakan Jalan. *Jurnal Teknik ITS*, 8(2). <https://doi.org/10.12962/J23373539.V8I2.49489>
- Probo Sumirat, L., Cahyono, D., & Ali Akbar, A. (2021). GEOGRAPHIC INFORMATION SYSTEM FOR REPORTING DAMAGE AND ROAD IMPROVEMENT IN THE NATIONAL ROAD IMPLEMENTATION CENTER VIII BASED ON WEB AND ANDROID. In *Jurnal Sistem Informasi Dan Bisnis Cerdas (SIBC)* (Vol. 14, Issue 1).
- Rachman, R., Septiarini, A., & Hamdani, H. (2022). Detection Of Road Damage Using Faster Regional-Convolutional Neural Network Method. *ICEECIT 2022 - Proceedings: 2022 International Conference on Electrical Engineering, Computer and Information Technology*, 54–59. <https://doi.org/10.1109/ICEECIT55908.2022.10030629>
- Rahman, F. I., Lukman, L., & Hildayati, H. (2025). Sistem Klasifikasi Kerusakan Jalan Metode Machine Learning dengan Algoritma K-Means dan Random Forest. *Arus Jurnal Sains Dan Teknologi*, 3(1), 116–126. <https://doi.org/10.57250/AJST.V3I1.1212>
- Rainio, O., Teuho, J., & Klén, R. (2024). Evaluation metrics and statistical tests for machine learning. *Scientific Reports*, 14(1). <https://doi.org/10.1038/s41598-024-56706-x>

- Ren, M., Zhang, X., Zhi, X., Wei, Y., & Feng, Z. (2024). An annotated street view image dataset for automated road damage detection. *Scientific Data*, 11(1), 1–13. <https://doi.org/10.1038/S41597-024-03263-7>;SUBJMETA
- Saha, P. K., Arya, D., & Sekimoto, Y. (2024). Federated learning–based global road damage detection. *Computer-Aided Civil and Infrastructure Engineering*, 39(14), 2223–2238. <https://doi.org/10.1111/mice.13186>
- Sasmito, B., Setiadji, B. H., & Isnanto, R. (2023). Deteksi Kerusakan Jalan Menggunakan Pengolahan Citra Deep Learning di Kota Semarang. *TEKNIK*, 44(1), 7–14. <https://doi.org/10.14710/teknik.v44i1.51908>
- Shaw, W., Wang, G., Ampofo, G. K. M., Befek, C. L., & Botei, D. (2025). An analysis of the symmetric and asymmetric relationship between road traffic casualties and economic development of Ghana. *Journal of Transport Geography*, 124, 104174. <https://doi.org/10.1016/J.JTRANGE.2025.104174>
- Siripathitti, P. (2023). *Data augmentations for improving vision-based damage detection in land transport infrastructure*.
- Siripathitti, P., Forest, F., & Fink, O. (n.d.). *Cut-and-Paste with Precision: a Content and Perspective-aware Data Augmentation for Road Damage Detection*.
- Sufia Zareen, Samia Hasan Suha, Kaosar Hossain, & Touhid Bhuiyan. (2025). AI-powered road damage detection for enhanced safety and life protection. *World Journal of Advanced Research and Reviews*, 27(1), 2169–2180. <https://doi.org/10.30574/wjarr.2025.27.1.2732>
- Tang, Y., Li, K., & Wang, K. (2022). Research on intelligent detection of pavement damage based on CNN. *Mathematical Models in Engineering*, 8(4), 98–107. <https://doi.org/10.21595/mme.2022.22918>
- Utaminigrum, F., Alqadri, A. M., Somawirata, I. K., Karim, C., Septiarini, A., Lin, C. Y., & Shih, T. K. (2023). Feature selection of gray-level Cooccurrence matrix using genetic algorithm with Extreme learning machine classification for early detection of Pole roads. *Results in Engineering*, 20. <https://doi.org/10.1016/j.rineng.2023.101437>
- Vishwakarma, R. (2020). *CNN Model & Tuning for Global Road Damage Detection*. IEEE.
- Vishwakarma, R., & Vennelakanti, R. (2020). CNN Model Tuning for Global Road Damage Detection. *Proceedings - 2020 IEEE International Conference on Big Data, Big Data 2020*, 5609–5615. <https://doi.org/10.1109/BigData50022.2020.9377902>
- Walsh, I., Fishman, D., Garcia-Gasulla, D., Titma, T., Pollastri, G., Capriotti, E., Casadio, R., Capella-Gutierrez, S., Cirillo, D., Del Conte, A., Dimopoulos, A. C., Del Angel, V. D., Dopazo, J., Fariselli, P., Fernández, J. M., Huber, F., Kreshuk, A., Lenaerts, T., Martelli, P. L., ... Tosatto, S. C. E. (2021). DOME: recommendations for supervised machine learning validation in biology. In *Nature Methods* (Vol. 18, Issue 10, pp. 1122–1127). Nature Research. <https://doi.org/10.1038/s41592-021-01205-4>

- Wang, J., Li, X., Xu, Y., Zhou, Z., Wu, W., & Li, Z. (2025). Optimizing CNN for pavement distress detection via edge-enhanced multi-scale feature fusion. *PLoS ONE*, 20(4 April). <https://doi.org/10.1371/journal.pone.0319299>
- Wang, J., Wang, K., & Li, K. (2023a). Research on road damage recognition and classification based on improved VGG-19. *Mathematical Models in Engineering*, 9(4), 115–129. <https://doi.org/10.21595/mme.2023.23455>
- Wang, J., Wang, K., & Li, K. (2023b). Research on road damage recognition and classification based on improved VGG-19. *Mathematical Models in Engineering*, 9(4), 115–129. <https://doi.org/10.21595/mme.2023.23455>
- Xu, H., Chen, B., & Qin, J. (2021). A cnn-based length-aware cascade road damage detection approach. *Sensors (Switzerland)*, 21(3), 1–19. <https://doi.org/10.3390/s21030689>
- Zhang, C., Nateghinia, E., Miranda-Moreno, L. F., & Sun, L. (2022). Pavement distress detection using convolutional neural network (CNN): A case study in Montreal, Canada. *International Journal of Transportation Science and Technology*, 11(2), 298–309. <https://doi.org/10.1016/J.IJTST.2021.04.008>

LAMPIRAN

Penjelasan lihat di ppt